# homework1

黄舟翔 3220103606

2025-06-26

**Q**1

a.

运行下列代码后,可以将 Iowa.csv 中的数据提取到 iowa.df 中。

```
iowa.df<-read.csv("data/Iowa.csv", sep = ';', header=T)</pre>
```

b.

运行下列代码后,可以查看 iowa.df 的行数和列数,由运行结果可知,iowa.df 有 33 行和 10 列。

```
dimensions <- dim(iowa.df)
cat("b. 数据框有", dimensions[1], " 行和", dimensions[2], " 列\n")
```

## b. 数据框有 33 行和 10 列

c.

可以通过下列代码获取 iowa.df 的列名。由运行结果可知,列名称为 Year, Rain0, Temp1, Rain1, Temp2, Rain2, Temp3, Rain3, Temp4, Yield

```
column_names <- names(iowa.df)
cat("c. 列名称为:", paste(column_names, collapse = ", "), "\n")
```

## c. 列名称为: Year, RainO, Temp1, Rain1, Temp2, Rain2, Temp3, Rain3, Temp4, Yield

d.

用下列代码获取第5行第7列的值,可得值为79.7。

```
value_5_7 <- iowa.df[5, 7]
cat("d. 第 5 行第 7 列的值是:", value_5_7, "\n")</pre>
```

## d. 第5行第7列的值是: 79.7

e.

用下列代码获取第2行的完整内容。

```
cat("e. 第二行的完整内容:\n")
```

## e. 第二行的完整内容:

```
print(iowa.df[2, ])
```

```
## Year Rain0 Temp1 Rain1 Temp2 Rain2 Temp3 Rain3 Temp4 Yield
## 2 1931 14.76 57.5 3.83 75 2.72 77.2 3.3 72.6 32.9
```

 $\mathbf{Q2}$ 

a.

max(vector1): 元素实际是字符类型。R 语言中会按照按字典序比较,即: 用 ASCII 值比较: "1"(49) < "3"(51) < "5"(53) < "7"(55)

故显示最大值为"7"

```
vector1 <- c("5", "12", "7", "32")
max(vector1)</pre>
```

## [1] "7"

sort(vector1): 按字符编码升序排列, 即: 首字符排序: 1 < 3 < 5 < 7 结果: "12", "32", "5", "7

```
vector1 <- c("5", "12", "7", "32")
sort(vector1)</pre>
```

```
## [1] "12" "32" "5" "7"
```

sum(vector1): 出现错误,因为字符向量不能直接数学运算。需先转换为数值型: sum(as.numeric(vector1)) 才能得到 56。

b.

- **1.** 会产生错误。vector2 创建时混合类型触发强制转换,vector2 实际值为 c("5", "7", "12")。故加法操作"7"+"12" 无意义
- 2. 数据框不要求各元素类型统一,故保留原始类型:

z1: 字符型 ("5")

z2: 数值型 (7)

z3: 数值型 (12)

dataframe3[1,2] 和 dataframe3[1,3] 提取数值元素

有效运算: 7+12=19

```
dataframe3 <- data.frame(z1="5", z2=7, z3=12)
dataframe3[1,2] + dataframe3[1,3]
```

## [1] 19

**3.** list4[[2]] → 42 (数值)

list4[[4]] → 126 (数值)

相加结果: 168

```
list4 <- list(z1="6", z2=42, z3="49", z4=126)
list4[[2]] + list4[[4]]
```

## [1] 168

**4.** list4[2] → 单元素列表

list4[4] → 单元素列表

列表加法非法

```
Q3
```

a.

用下列代码可以实现。

```
seq1 <- seq(from = 1, to = 10000, by = 372)
seq2 <- seq(from = 1, to = 10000, length.out = 50)</pre>
```

b.

times = n:

将整个向量重复n次

模式: (元素 1, 元素 2, ...) → 整体重复

each = n:

将每个元素连续重复n次

模式: 元素 1×n, 元素 2×n, ...

```
rep(1:3, times = 3)
```

## [1] 1 2 3 1 2 3 1 2 3

```
rep(1:3, each = 3)
```

## [1] 1 1 1 2 2 2 3 3 3

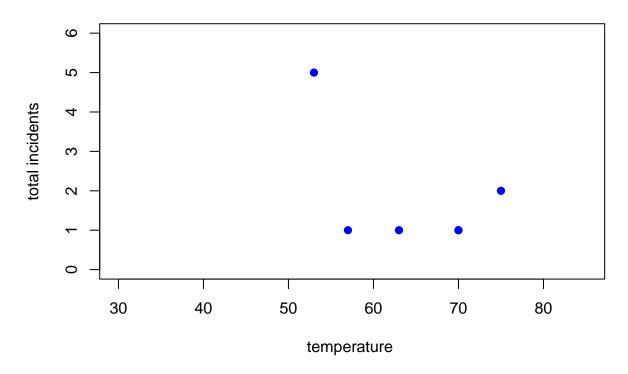
### **MB.CH1.2**

用以下代码解决问题。

```
data(orings)
# 创建子集数据框
selected_rows <- c(1, 2, 4, 11, 13, 18)
orings_subset <- orings[selected_rows, ]
data(orings)
```

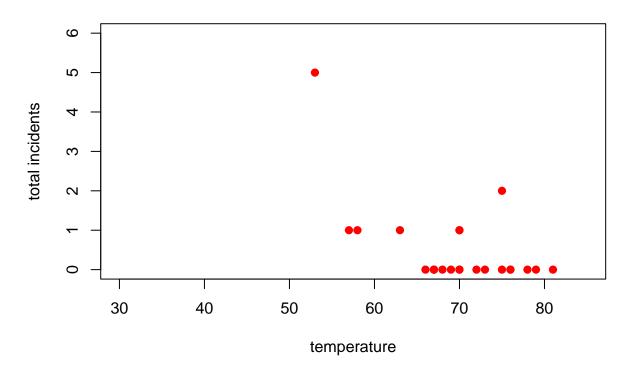
```
# 安装并加载 DAAG 包 (如果未安装)
if (!require("DAAG")) install.packages("DAAG")
library(DAAG)
# 加载 orings 数据集
data(orings)
# 提取指定行创建新数据框
selected_rows <- c(1, 2, 4, 11, 13, 18)
orings_subset <- orings[selected_rows, ]</pre>
#添加总事故次数列 (Erosion + Blowby)
orings_subset$Total_incidents <- orings_subset$Erosion + orings_subset$Blowby
orings$Total_incidents <- orings$Erosion + orings$Blowby</pre>
#绘制子集数据的图形
plot(Total_incidents ~ Temperature,
    data = orings_subset,
    main = "critical: total incidents vs temperature",
    xlab = "temperature ",
    ylab = "total incidents",
    pch = 19, col = "blue",
    xlim = c(30, 85), ylim = c(0, 6))
```

# critical: total incidents vs temperature



```
# 绘制完整数据的图形
plot(Total_incidents ~ Temperature,
    data = orings,
    main = "full: total incidents vs temperature",
    xlab = "temperature",
    ylab = "total incidents",
    pch = 19, col = "red",
    xlim = c(30, 85), ylim = c(0, 6))
```

# full: total incidents vs temperature



### **MB.CH1.4**

a.

用以下代码解决问题。不存在缺失的列。

```
library(DAAG)
str(ais)
```

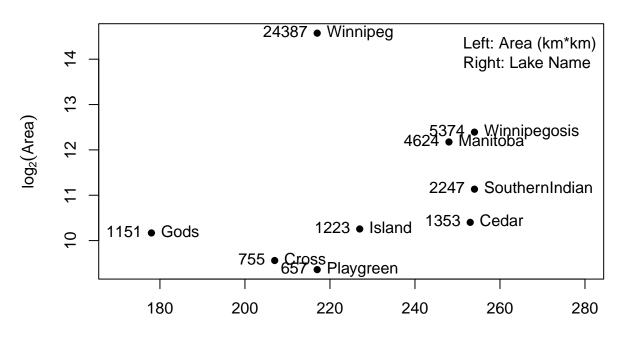
```
202 obs. of 13 variables:
## 'data.frame':
                   3.96 4.41 4.14 4.11 4.45 4.1 4.31 4.42 4.3 4.51 ...
                  7.5 8.3 5 5.3 6.8 4.4 5.3 5.7 8.9 4.4 ...
##
    $ wcc
            : num
                   37.5 38.2 36.4 37.3 41.5 37.4 39.6 39.9 41.1 41.6 ...
    $ hc
##
            : num
                   12.3 12.7 11.6 12.6 14 12.5 12.8 13.2 13.5 12.7 ...
    $ hg
##
            : num
    $ ferr
                   60 68 21 69 29 42 73 44 41 44 ...
           : num
                   20.6 20.7 21.9 21.9 19 ...
    $ bmi
            : num
            : num 109.1 102.8 104.6 126.4 80.3 ...
    $ ssf
##
    $ pcBfat: num 19.8 21.3 19.9 23.7 17.6 ...
```

```
$ 1bm
           : num 63.3 58.5 55.4 57.2 53.2 ...
           : num 196 190 178 185 185 ...
   $ ht
          : num 78.9 74.4 69.1 74.9 64.6 63.7 75.2 62.3 66.5 62.9 ...
## $ wt
          : Factor w/ 2 levels "f", "m": 1 1 1 1 1 1 1 1 1 ...
## $ sex
## $ sport : Factor w/ 10 levels "B_Ball", "Field", ...: 1 1 1 1 1 1 1 1 1 1 ...
colSums(is.na(ais))
                    hc
                               ferr
                                              ssf pcBfat
                                                            1bm
##
     rcc
            WCC
                           hg
                                       bmi
                                                                   ht
                                                                          wt
##
       0
              0
                            0
                                         0
                                                              0
                                                                    0
                                                                           0
##
     sex sport
##
       0
              0
b.
用一下代码解决问题。
# 创建性别-运动项目交叉表
gender_sport_table <- table(ais$sport, ais$sex)</pre>
# 计算男女比例 (男性比例)
male_ratio <- gender_sport_table[, "m"] / rowSums(gender_sport_table)</pre>
# 识别失衡项目 (男性比例 > 2/3 或 < 1/3)
imbalanced_sports <- names(which(male_ratio > 2/3 | male_ratio < 1/3))</pre>
# 打印结果
print("性别-运动项目分布表:")
## [1] "性别-运动项目分布表:"
print(gender_sport_table)
##
             f m
##
    B_Ball 13 12
##
    Field
##
             7 12
##
     Gym
    Netball 23 0
##
##
            22 15
    Row
```

```
Swim
           9 13
##
    T 400m 11 18
##
##
    T_Sprnt 4 11
    Tennis 7 4
##
    W_Polo 0 17
##
cat("\n性别比例失衡的运动项目(比例 > 2:1):")
##
## 性别比例失衡的运动项目(比例 > 2:1):
print(imbalanced_sports)
## [1] "Gym"
             "Netball" "T_Sprnt" "W_Polo"
MB.CH1.6
a.
Y 轴刻度:表示 log2(面积)
Y 轴增加 2 单位 → 面积变为 4 倍 (2<sup>2</sup> = 4 倍)
Y 轴增加 3 单位 → 面积变为 8 倍 (2^3 = 8) 倍
点标签:
左侧数字:实际面积(km²)
右侧文字:湖泊名称
关键观察:
Winnipeg 湖面积最大 (log₂(24387)≈14.6), 远大于其他湖泊
Gods 湖海拔最低但面积中等(178m, 1151km²)
海拔与面积无明显相关性
Manitoba.lakes <- data.frame(</pre>
 elevation = c(217, 254, 248, 254, 253, 227, 178, 207, 217),
 area = c(24387, 5374, 4624, 2247, 1353, 1223, 1151, 755, 657)
```

)

# **Manitoba's Largest Lakes (Logarithmic Scale)**



Note: Each unit increase delevatione (me) ents doubling of lake area

b.

Y 轴刻度: 对数变换后等距

从 500 到 1000 的距离 = 从 1000 到 2000 的距离 (均表示面积翻倍)

大湖 (Winnipeg) 与小湖 (Cross) 差异更明显

优势:

直接显示实际面积值

保持面积比例关系直观

避免 Winnipeg 湖压缩其他数据点

与(a)对比:

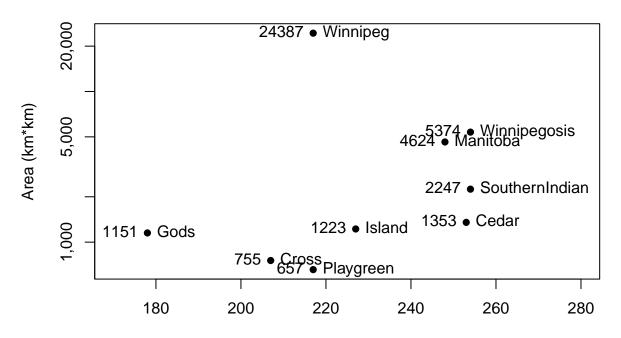
相同的数据关系

不同的视觉表示

对数Y轴图更易解释面积差异

```
# 创建对数 Y 轴图形
plot(area ~ elevation, data = Manitoba.lakes, pch = 16,
    xlim = c(170, 280), log = "y",
    xlab = "Elevation (m)", ylab = "Area (km*km)",
    main = "Manitoba's Largest Lakes (Logarithmic Y-axis)",
    yaxt = "n") # 禁用默认 Y 轴
#添加自定义对数刻度
axis(2, at = c(500, 1000, 2000, 5000, 10000, 20000),
    labels = c("500", "1,000", "2,000", "5,000", "10,000", "20,000"))
#添加湖泊名称标签 (右侧)
text(Manitoba.lakes$elevation, Manitoba.lakes$area,
    labels = row.names(Manitoba.lakes), pos = 4)
#添加面积数值标签 (左侧)
text(Manitoba.lakes$elevation, Manitoba.lakes$area,
    labels = Manitoba.lakes$area, pos = 2)
#添加比例解释
mtext("Note: Vertical distances represent multiplicative differences in area",
   side = 1, line = 3, cex = 0.8)
```

## Manitoba's Largest Lakes (Logarithmic Y-axis)



Note: Vertical distances replessation u(trp)icative differences in area

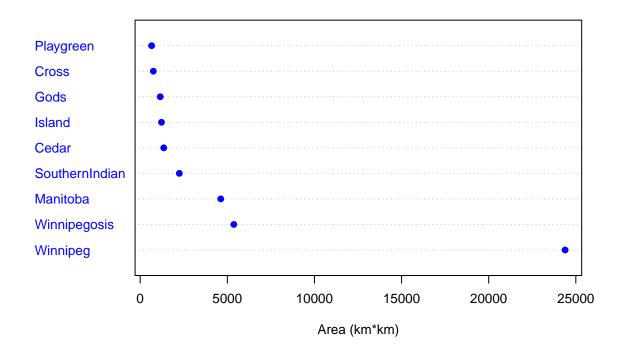
关键结论:两种对数表示都揭示了Winnipeg 湖的绝对主导地位(占所有湖泊总面积的约70%),但未显示海拔与面积的显著相关性。对数变换对于可视化跨度大的面积数据至关重要。

#### **MB.CH1.7**

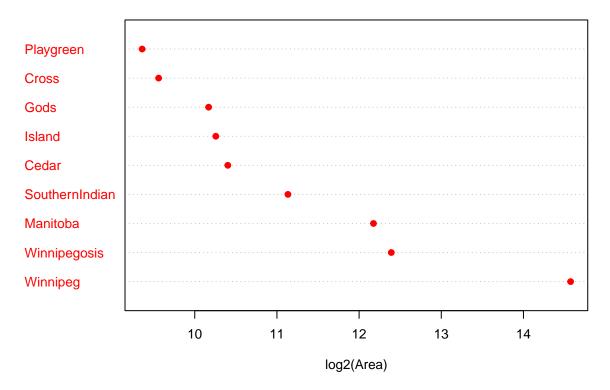
用以下代码完成。

```
labels = rownames(Manitoba.lakes),
main = "lake Area (linear scale)",
xlab = "Area (km*km)",
pch = 19, col = "blue",
cex = 0.8)
```

### lake Area (linear scale)



### lake Area (logarithmic scale: log2)



#### **MB.CH1.8**

## 马尼托巴省水域面积下界: 41,771 平方公里

```
      cat("\n说明: ",

      "\n• 此计算基于马尼托巴省 9 个主要湖泊的面积总和",

      "\n• 实际水域面积更大(包含未统计的小型湖泊、河流和湿地)",

      "\n• 因此", format(water_area_lower_bound, big.mark = ","),

      " 平方公里仅为最小估计值")
```

### ##

### ## 说明:

- ## 此计算基于马尼托巴省9个主要湖泊的面积总和
- ## 实际水域面积更大(包含未统计的小型湖泊、河流和湿地)
- ## 因此 41,771 平方公里仅为最小估计值